

COMPUTACIÓN DE ALTO DESEMPEÑO · PYSPARK + KERAS

Calidad del Agua en Ríos de la India

Diagnóstico del Índice de Calidad del Agua (WQI) mediante Regresión Lineal distribuida (MLlib) y Red Neuronal profunda (TensorFlow/Keras) sobre datos reales de 18 estados.

AUTOR

Juan Sebastián Bravo Santacruz

INSTITUCIÓN

Pontificia Universidad Javeriana

FECHA

Mayo 2026

ENTORNO

Apache Spark 3.5.5 · TensorFlow/Keras

534

REGISTROS BRUTOS

447

REGISTROS LIMPIOS

18

ESTADOS

2

MODELOS ML

$R^2=1.0$

MLLIB R^2

01 · PROBLEMA & OBJETIVO

¿Por qué predecir la calidad del agua?

India enfrenta uno de los mayores retos de contaminación fluvial del mundo. Este proyecto aplica HPC sobre mediciones fisicoquímicas de 18 estados para construir y predecir el WQI con dos enfoques de Machine Learning.

Metodología: Pesos ponderados según IntechOpen, Cap. 69568.

- 1

Importación desde HDFS

Lectura del CSV en clúster Spark
- 2

Preprocesamiento & EDA

Tipos, nulos, estadísticas, visualizaciones
- 3

Construcción del WQI

Cálculo mediante pesos bibliográficos
- 4

Entrenamiento de modelos

Regresión Lineal (MLlib) + Red Neuronal (Keras)
- 5

Evaluación & Conclusiones

RMSE, MAE, R² – comparativa final

02 · CARGA DE DATOS

Dataset: Ríos de India

534

Registros orig.

11

Columnas

447

Tras limpieza



18

Estados



Filas eliminadas con nulos → 534 → 447 registros (≈16% pérdida).

Distribución & Comportamiento de los Parámetros

Estadístico	TEMP (°C)	DO (mg/L)	pH	CONDUCTIVITY (µS/cm)	BOD (mg/L)	Nitratos (mg/L)	Col. Fecales (UFC)
Media	25.24	6.39	7.80	684.98	5.34	1.38	7,384
Desv. Est.	3.45	1.62	0.65	1,769.33	8.50	2.80	30,714
Min / Máx	10.5 / 33.8	0.0 / 16.3	6.3 / 14.7	39 / 24,062	0.2 / 75.6	0.0 / 45.5	0 / 310,417



Parámetros de Contaminación



Resumen EDA: Coliformes Fecales y Conductividad son las variables con mayor impacto y distribuciones más sesgadas. El DO registra caídas críticas localizadas. Estos hallazgos determinan los pesos del WQI.

Construcción del WQI

Suma ponderada de subíndices para cada parámetro. Cada parámetro se transforma en un **puntaje de calidad** (0 / 40 / 60 / 80 / 100) según rangos definidos, luego se multiplica por su peso bibliográfico.


PESOS WQI

BIBLIOGRAFÍA

```
# Pesos por parámetro (suman ≈ 100)
pesos = {
  'DO'           : 28.10, # Oxígeno Disuelto
  'FECAL_COLIFORM' : 28.10, # Coliformes fecales
  'pH'           : 16.50, # Acidez/alcalinidad
  'CONDUCTIVITY'  : 9.36, # Conductividad
  'NITRATE'       : 2.80, # Nitratos/nitritos
  'BOD'           : 0.72, # Demanda O2
}
```

Ref.: Omer, N.H. (2019). *Water Quality Parameters*. IntechOpen. [intechopen.com/chapters/69568](https://www.intechopen.com/chapters/69568)



Pesos del WQI por Parámetro



Categorías de Calidad

Rango WQI	Categoría	Estaciones	%
< 25	Excelente	11	2.46%
25 – 50	Buena	95	21.25%
50 – 75	Baja ★	271	60.63%
75 – 100	Muy Baja	70	15.66%

WQI por Estado y Mapa Nacional



05 · MODELOS DE MACHINE LEARNING

Regresión Lineal vs. Red Neuronal

Regresión Lineal – MLlib

DISTRIBUIDO

PIPELINE MLlib

PYSPARK ML

```
# Ensamblado + escala + regresión
assembler = VectorAssembler(
    inputCols=['DO','pH','CONDUCTIVITY',
               'BOD','NITRATE_N','NITRITE_N',
               'FECAL_COLIFORM'],
    outputCol='features_raw')
scaler = StandardScaler(
    inputCol='features_raw', outputCol='features')
lr = LinearRegression(
    featuresCol='features', labelCol='WQI')
pipeline = Pipeline(stages=[assembler,scaler,lr])
model = pipeline.fit(train_df)
```

Red Neuronal – Keras / TensorFlow

DRIVER LOCAL


ARQUITECTURA KERAS

TF / KERAS

```
model = Sequential([
    Dense(64, activation='relu',
          input_shape=(X_train.shape[1],)),
    Dropout(0.2),
    Dense(32, activation='relu'),
    Dropout(0.1),
    Dense(1) # Salida: WQI predicho
])
model.compile(optimizer='adam', loss='mse')
es = EarlyStopping(monitor='val_loss', patience=10,
                   restore_best_weights=True)
```

Convergencia Keras – Curvas de Pérdida

~38 ÉPOCAS · EARLYSTOPPING




Convergencia rápida en las primeras 5 épocas. MSE y MAE de entrenamiento y validación se alinean. El **EarlyStopping** detuvo correctamente el entrenamiento antes del sobreajuste.

Nota sobre entornos: MLlib corre de forma distribuida en el clúster Spark. Keras se ejecuta en el driver local convirtiendo el DataFrame a Pandas/NumPy antes del entrenamiento.

Desempeño Comparativo


MLlib ★ MEJOR	
RMSE	0.0726
MAE	0.0200
R ²	1.0000
Entorno	Spark Cluster

Keras	
RMSE	4.2619
MAE	3.0545
R ²	0.9187
Entorno	Driver local TF




MLlib – Predicción vs Real

SCATTER PLOT



Keras – Predicción vs WQI Real

TRAIN & TEST



07 · CONCLUSIONES & RECOMENDACIONES

Hallazgos Clave del Proyecto



Outliers

- Conductividad fuertemente sesgada hacia valores extremos.
- BOD con picos por descargas orgánicas puntuales.
- Coliformes: media 7,384 vs máx. 310,417 — distribución muy asimétrica.



WQI

- Categoría Baja domina (~60% de estaciones).
- Punjab: mejor calidad (WQI 37.2).
- Kerala: peor (WQI 83.9).
- Diferencias regionales significativas.



Modelos

- Regresión Lineal supera a la Red Neuronal en todas las métricas.
- Naturaleza lineal del WQI favorece modelos lineales.
- MLlib: escalable en entorno distribuido.



General

- Calidad heterogénea con predominio del nivel Bajo.
- PySpark + HDFS: pipeline reproducible y escalable.
- Recomendado seguimiento en estaciones con outliers.

08 · REFERENCIAS BIBLIOGRÁFICAS

1. Apache Spark. *PySpark MLlib Linear Regression Documentation*. spark.apache.org/docs/latest/LinearRegression.html
2. Keras. *The Sequential Model*. keras.io/guides/sequential_model/
3. TensorFlow. *tf.keras.Sequential*. tensorflow.org/api_docs/python/tf/keras/Sequential
4. Scikit-learn. *Metrics and scoring: quantifying the quality of predictions*. scikit-learn.org/stable/modules/model_evaluation.html
5. Scikit-learn. *r2_score*. scikit-learn.org/stable/modules/r2_score.html
6. Omer, N.H. (2019). *Water Quality Parameters*. IntechOpen. intechopen.com/chapters/69568