

COMPUTACIÓN DE ALTO DESEMPEÑO · PYSPARK + KERAS

Calidad del Agua en Ríos de la India

Diagnóstico del Índice de Calidad del Agua (WQI) mediante Regresión Lineal distribuida (MLlib) y Red Neuronal profunda (TensorFlow/Keras) sobre datos reales de 18 estados.

AUTOR	INSTITUCIÓN	FECHA	ENTORNO
Juan Sebastián Bravo Santacruz	Pontificia Universidad Javeriana	Mayo 2026	Apache Spark 3.5.5 · TensorFlow/Keras

534	447	18	2	R ² =1.0
REGISTROS BRUTOS	REGISTROS LIMPIOS	ESTADOS	MODELOS ML	MLLIB R ²

WQI

01 · PROBLEMA & OBJETIVO

¿Por qué predecir la calidad del agua?

India enfrenta uno de los mayores retos de contaminación fluvial del mundo. Este proyecto aplica HPC sobre mediciones físicoquímicas de 18 estados para construir y predecir el WQI con dos enfoques de Machine Learning.

Metodología: Pesos ponderados según IntechOpen, Cap. 69568.

- 1

Importación desde HDFS

Lectura del CSV en clúster Spark
- 2

Preprocesamiento & EDA

Tipos, nulos, estadísticas, visualizaciones
- 3

Construcción del WQI

Cálculo mediante pesos bibliográficos
- 4

Entrenamiento de modelos

Regresión Lineal (MLlib) + Red Neuronal (Keras)
- 5

Evaluación & Conclusiones

RMSE, MAE, R² – comparativa final

02 · CARGA DE DATOS

Dataset: Ríos de India

534

Registros orig.

11

Columnas

447

Tras limpieza

18

Estados



Columna	Descripción	Unidad
TEMP	Temperatura del agua	°C
DO	Oxígeno Disuelto (mayor = mejor)	mg/L
pH	Acidez/alcalinidad	adim.
CONDUCTIVITY	Conductividad eléctrica	µS/cm
BOD	Demanda Bioquímica de Oxígeno	mg/L
NITRATE_N_NITRITE_N	Nitratos/Nitritos	mg/L
FECAL_COLIFORM	Bacterias coliformes fecales	UFC/100mL

Columna	Nulos	Estado
FECAL_COLIFORM	82	Mayor número
CONDUCTIVITY	30	Con nulos
BOD / TEMP	6 / 5	Con nulos
pH	0	Limpio

Filas eliminadas con nulos → 534 → 447 registros (≈16% pérdida).

Distribución & Comportamiento de los Parámetros

Estadístico	TEMP (°C)	DO (mg/L)	pH	CONDUCTIVITY (µS/cm)	BOD (mg/L)	Nitratos (mg/L)	Col. Fecales (UFC)
Media	25.24	6.39	7.80	684.98	5.34	1.38	7,384
Desv. Est.	3.45	1.62	0.65	1,769.33	8.50	2.80	30,714
Min / Máx	10.5 / 33.8	0.0 / 16.3	6.3 / 14.7	39 / 24,062	0.2 / 75.6	0.0 / 45.5	0 / 310,417




03 · ANÁLISIS EXPLORATORIO (CONTINUACIÓN)

Parámetros de Contaminación

BOD y Nitratos/Nitritos


CONTAMINACIÓN ORGÁNICA



BOD supera con frecuencia el límite de 3 mg/L, picos hasta 75 mg/L (alta carga orgánica). Los **nitratos** son generalmente bajos; sus picos coinciden con zonas agrícolas de alto riego.

Conductividad y Coliformes Fecales

PARÁMETROS DE CONTAMINACIÓN



Coliformes Fecales (escala log): 1 hasta >100,000 UFC/100mL — máxima variabilidad del dataset. **Conductividad** con picos aislados de alta concentración iónica: descargas industriales puntuales.

Resumen EDA: Coliformes Fecales y Conductividad son las variables con mayor impacto y distribuciones más sesgadas. El DO registra caídas críticas localizadas. Estos hallazgos determinan los pesos del WQI.

04 · ÍNDICE DE CALIDAD DEL AGUA (WQI)

Construcción del WQI

Suma ponderada de subíndices para cada parámetro. Cada parámetro se transforma en un **puntaje de calidad** (0 / 40 / 60 / 80 / 100) según rangos definidos, luego se multiplica por su peso bibliográfico.

PESOS WQI


BIBLIOGRAFÍA

Pesos por parámetro (suman ≈ 100)

pesos = {
 'DO' : 28.10, # Oxígeno Disuelto
 'FECAL_COLIFORM': 28.10, # Coliformes fecales
 'pH' : 16.50, # Acidez/alcalinidad
 'CONDUCTIVITY' : 9.36, # Conductividad
 'NITRATE' : 2.80, # Nitratos/nitritos
 'BOD' : 0.72, # Demanda O₂
}

Ref.: Omer, N.H. (2019). *Water Quality Parameters*. IntechOpen. intechopen.com/chapters/69568

Pesos del WQI por Parámetro




Categorías de Calidad

Rango WQI	Categoría	Estaciones	%
< 25	Excelente	11	2.46%
25 – 50	Buena	95	21.25%
50 – 75	Baja ★	271	60.63%
75 – 100	Muy Baja	70	15.66%

WQI por Estado y Mapa Nacional

Distribución de Categorías WQI


447 ESTACIONES



Categoría **Baja** (~60%) domina. Solo 11 estaciones alcanzan calidad **Excelente**. La mayoría de ríos monitoreados presenta agua de calidad moderada a deficiente.

WQI Medio por Estado


RANKING ESTATAL



Punjab WQI 37.2 (mejor). Kerala WQI 83.9 (peor). Mayoría de estados oscila entre 50-70. Menor WQI = mejor calidad.

Mapa WQI por Estado – India

GEOESPACIAL



Mayoría del territorio en naranja (WQI 50-75 — moderada a baja). Himachal Pradesh en rojo (WQI 75-100). Punjab y noreste son las mejores regiones.

05 · MODELOS DE MACHINE LEARNING

Regresión Lineal vs. Red Neuronal

Regresión Lineal – MLlib **DISTRIBUIDO**

PIPELINE MLlib

PYSPARK ML

```
# Ensamblado + escala + regresión
assembler = VectorAssembler(
    inputCols=['DO','pH','CONDUCTIVITY',
               'BOD','NITRATE_N','NITRITE_N',
               'FECAL_COLIFORM'],
    outputCol='features_raw')
scaler = StandardScaler(
    inputCol='features_raw', outputCol='features')
lr = LinearRegression(
    featuresCol='features', labelCol='WQI')
pipeline = Pipeline(stages=[assembler,scaler,lr])
model = pipeline.fit(train_df)
```

Red Neuronal – Keras / TensorFlow **DRIVER LOCAL**


ARQUITECTURA KERAS

TF / KERAS

```
model = Sequential([
    Dense(64, activation='relu',
          input_shape=(X_train.shape[1],)),
    Dropout(0.2),
    Dense(32, activation='relu'),
    Dropout(0.1),
    Dense(1) # Salida: WQI predicho
])
model.compile(optimizer='adam', loss='mse')
es = EarlyStopping(monitor='val_loss', patience=10,
                   restore_best_weights=True)
```

Convergencia Keras – Curvas de Pérdida

~38 ÉPOCAS · EARLYSTOPPING



Convergencia rápida en las primeras 5 épocas. MSE y MAE de entrenamiento y validación se alinean. El **EarlyStopping** detuvo correctamente el entrenamiento antes del sobreajuste.


Nota sobre entornos: MLlib corre de forma distribuida en el clúster Spark. Keras se ejecuta en el driver local convirtiendo el DataFrame a Pandas/NumPy antes del entrenamiento.

Desempeño Comparativo

MLlib	★ MEJOR
RMSE	0.0726
MAE	0.0200
R ²	1.0000
Entorno	Spark Cluster

Keras	
RMSE	4.2619
MAE	3.0545
R ²	0.9187
Entorno	Driver local TF


Comparación de Métricas RMSE · MAE · R² TEST SET



Regresión Lineal R²=1.0 – esperable dado que el WQI es combinación lineal exacta. Red Neuronal R²=0.92 – robusta pero sin ventaja sobre la relación lineal pura.

MLlib – Predicción vs Real


SCATTER PLOT



Puntos casi perfectamente alineados con la línea ideal. Dispersión mínima por precisión numérica del cómputo distribuido en punto flotante.

Keras – Predicción vs WQI Real

TRAIN & TEST



Train R²=0.9484 / Test R²=0.9187. Buena generalización sin sobreajuste. Mayor dispersión en WQI bajo (20-40) por escasez de ejemplos de entrenamiento.

07 · CONCLUSIONES & RECOMENDACIONES

Hallazgos **Clave** del Proyecto



Outliers

- Conductividad fuertemente sesgada hacia valores extremos.
- BOD con picos por descargas orgánicas puntuales.
- Coliformes: media 7,384 vs máx. 310,417 — distribución muy asimétrica.



WQI

- Categoría Baja domina (~60% de estaciones).
- Punjab: mejor calidad (WQI 37.2).
- Kerala: peor (WQI 83.9).
- Diferencias regionales significativas.



Modelos

- Regresión Lineal supera a la Red Neuronal en todas las métricas.
- Naturaleza lineal del WQI favorece modelos lineales.
- MLlib: escalable en entorno distribuido.



General

- Calidad heterogénea con predominio del nivel Bajo.
- PySpark + HDFS: pipeline reproducible y escalable.
- Recomendado seguimiento en estaciones con outliers.

08 · REFERENCIAS BIBLIOGRÁFICAS

1. Apache Spark. *PySpark MLlib Linear Regression Documentation*. spark.apache.org/docs/latest/ml-linear.html
2. Keras. *The Sequential Model*. keras.io/guides/sequential_model/
3. TensorFlow. *tf.keras.Sequential*. [tensorflow.org/api_docs/python/tf/keras/Sequential](https://www.tensorflow.org/api_docs/python/tf/keras/Sequential)
4. Scikit-learn. *Metrics and scoring: quantifying the quality of predictions*. scikit-learn.org/stable/modules/model_evaluation.html
5. Scikit-learn. *r2_score*. scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html
6. Omer, N.H. (2019). *Water Quality Parameters*. IntechOpen. [intechopen.com/chapters/69568](https://www.intechopen.com/chapters/69568)